


# Lezione04

## Table of contents

- [Funzioni reali di più variabili reali](#)
  1. [Dominio e codominio](#)
  2. [Limite](#)
  3. [Derivata direzionale](#)
  4. [Derivata parziale](#)
  5. [Gradiente della funzione](#)
  6. [Massimi e minimi](#)
- [Algoritmo di discesa del gradiente](#)
- [Illustrazioni di alcuni punti stazionari](#)

## Funzioni reali di più variabili reali

### Dominio e codominio




Dati  $n, m \in \mathbb{N}_+$ , considerando **dominio**  $D \subseteq \mathbb{R}^n$  e **codominio**  $C \subseteq \mathbb{R}^m$ , la funzione

$$f: D \rightarrow C$$

è una funzione vettoriale con  $m$  componenti e  $n$  variabili reali.

#### Il dominio di $\sqrt{x}$

Se non chiaro, visualizziamo il dominio, ragionando nell'insieme dei reali  $\mathbb{R}^n$ , come l'insieme dei valori che una funzione  $f(x)$  può assumere. La funzione  $f(x) = \sqrt{x}$  ha come dominio, tutti i numeri reali non negativi.




Viene prodotto un vettore come risultato, il che significa che possiamo riscrivere

$$f(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x}))$$

Ci concentreremo sullo studio di più funzioni reali che produrranno una variabile reale: i vettori li potremo spezzare e studiare per ogni singola componente.

### Limite



Per lo studio delle funzioni, riprendiamo il concetto di limite di funzione.

Considerando una funzione  $f$  su sotto dominio di  $\mathbb{R}^n$ , e il dominio aperto  $D \subseteq \mathbb{R}^n$ , diremo che possiamo avvicinarci a un punto contenuto in questa palla da qualsiasi direzione, scrivendo il **limite** come

$$\lim_{\mathbf{x} \rightarrow \mathbf{w}} f(\mathbf{x}) = l$$

e che esiste, se e soltanto se esiste la  $\epsilon$  delta ("**epsilon delta**")

$$\forall \epsilon \in \mathbb{R}_+ \quad \exists \delta \in \mathbb{R}_+ : \forall \mathbf{x} \in D \quad ||\mathbf{x} - \mathbf{w}|| < \delta \implies |f(\mathbf{x}) - l| < \epsilon$$


L'affermazione dice: se esiste il limite esiste una tolleranza positiva, che chiamiamo  $\epsilon$ , la quale può essere contenuta da una palla di raggio  $D$ . Possiamo guardare l'immagine sopra per intenderci meglio: notare come la funzione  $f(x)$  tenda a questa differenza assoluta, che è a sua volta  $< \epsilon$  (la nomenclatura è diversa, ma rende comunque l'idea).

La funzione  $f$  ha come limite  $l$  per  $\mathbf{x}$  che tende a infinito

$$\lim_{\mathbf{x} \rightarrow \infty} f(\mathbf{x}) = l$$

se allontanandoci sempre di più da  $m$ , ci avviciniamo sempre di più a  $\epsilon$

$$\forall \epsilon \in \mathbb{R}_+ \quad \exists m \in \mathbb{R}_+ : \forall \mathbf{x} \in D \quad ||\mathbf{x}|| > m \implies |f(\mathbf{x}) - l| < \epsilon$$



La funzione  $1/x^2$  tende a  $\infty$

Questa proposizione ci servirà per definire gli integrali impropri e la continuità della funzione; lo studio asintotico quindi ci serve: il processo d'addestramento che andiamo a fare su una rete neurale, ha lo scopo di minimizzare l'errore sull'approssimazione. Siccome quello che andremo a fare è minimizzare l'errore, capiremo se esiste per davvero questo minimo e se varrà la pena di cercarlo.


## Derivata direzionale

Consideriamo la solita funzione  $f$  definita per un aperto  $D \subseteq \mathbb{R}^n$ , consideriamo inoltre un punto che appartenga al dominio  $\mathbf{x} \in D$ , insieme a un versore  $\mathbf{v} \in \mathbb{R}^n$  che ci indica una direzione. Ci poniamo il problema di capire se esiste il limite per  $h$  che tende a 0, della quantità che segue in rapporto

$$\partial_{\mathbf{v}} f(\mathbf{x}) \triangleq \lim_{h \rightarrow 0} \frac{f(\mathbf{x} + h\mathbf{v}) - f(\mathbf{x})}{h}$$

Osservando il limite, ci viene da dire che in effetti  $\mathbf{x}$  esiste siccome appartenente al dominio; esiste quindi


anche il limite di  $\mathbf{x}$  che punta nella direzione  $\mathbf{v}$ ? Fintanto che  $h$  assuma valori sufficientemente piccoli, allora lo possiamo confermare. Questo limite viene detto **derivata direzionale nella direzione  $\mathbf{v}$  della funzione  $f$  nel punto  $\mathbf{x}$** .



(Osserviamo l'immagine) Abbiamo una funzione di due variabili  $x_1$  e  $x_2$ . Fissiamo un punto  $x$  su cui la funzione è definita.  $f(x)$  è la quota rappresentata sulla superficie. Scegliendo una direzione  $v$ , che rimarrà sempre la stessa, ci avviciniamo lungo questa direzione, al punto  $x$ , calcolando il rapporto incrementale che nel caso abbia limite (tendono a qualche cosa), confermerà l'esistenza di una derivata direzionale.

Quello che andiamo a ottenere, è in realtà una linea, che corre sulla superficie e si avvicina a due punti: il coefficiente angolare di questa retta è la derivata in quel punto.

## Derivata parziale



Le derivate direzionali ci interessano in un caso particolare: se la direzione è parallela a uno degli assi. Anziché prendere un  $v$  che è inclinato, ne prendiamo uno parallelo a  $x_1$  oppure uno parallelo a  $x_2$ . Nell'insieme  $\mathbb{R}^n$  ne esisteranno un numero infinito  $n$  di questi **versori ortonormali** (lunghezza 1 e paralleli agli assi).

Per esempio: se prendessimo un punto  $x$  lungo il piano, e girassimo il vettore  $v$  per renderlo parallelo a  $x_1$ , allora tutte le componenti del vettore saranno a 0 tranne che per la componente la quale descrive la posizione rispetto appunto  $x_1$ .

$$\mathbf{v} = (0, 0, \dots, 1, 0, 0, \dots, 0)$$

Se utilizziamo uno di questi per calcolare la nostra derivata, essa prenderà il nome di **derivata parziale**, scritta come

$$\frac{\partial f}{\partial x_i}(\mathbf{x}) \quad \text{oppure} \quad \partial_i f(\mathbf{x})$$


Siccome il nostro punto prende ora in considerazione una sola variabile (l'asse che rimane fisso), il calcolo che andremo a eseguire prenderà solo in considerazione questo, mentre le altre variabili saranno costanti e non ci interesseranno (fissate a 0).

$$f(x, y, z) = 3x^2 + 5xy - 7z^3$$

allora la derivata parziale lungo  $x, y, z$  usa le normali regole di derivazione

$$\nabla f(x, y, z) = (6x + 5y, 5x, -21z^2)$$

## Gradiente della funzione



Se esiste il vettore formato dalle  $n$  derivate parziali di una funzione in  $\mathbf{x}$ , questo viene detto **gradiente della funzione** e si indica con

$$\nabla f(\mathbf{x}) \triangleq \left( \frac{\partial f}{\partial x_1}(\mathbf{x}), \frac{\partial f}{\partial x_2}(\mathbf{x}), \dots, \frac{\partial f}{\partial x_n}(\mathbf{x}) \right)$$

(Osserviamo l'immagine) Prendiamo la nostra funzione  $f$  con tutte le sue depressioni, prendiamo un punto  $x$  in cui la funzione esiste, calcoliamo le due derivate parziali una lungo l'asse  $x_1$  e l'altra lungo l'asse  $x_2$ , quello che otterremo sarà un vettore  $\nabla f(\mathbf{x})$  che prende il nome di gradiente.

Notiamo che:

- se la funzione è esplicitata in formula, questo gradiente sarà semplice da calcolare;
- il nostro gradiente conterrà tutte le informazioni, sull'andamento locale della funzione in prossimità del punto che abbiamo scelto;
- non ha importanza quali derivate vengano calcolate per prime, in quanto se esistenti, allora non cambieranno il risultato finale.

⇒ **Derivare parzialmente prima una variabile piuttosto che un'altra, non cambia il senso del gradiente, che rimarrà lo stesso**

$$f(x, y, z) = 3x^2 + 5xy - 7z^2$$

allora

$$\frac{\partial^2 f}{\partial x \partial y}(x, y, z) = \frac{\partial^2 f}{\partial y \partial x}(x, y, z) = 5$$

Nota la funzione e le sue derivate parziali, ci è possibile calcolare la derivata lungo una direzione arbitraria. Non è più necessario calcolare il limite del rapporto incrementale o girare gli assi, ci basta fare il prodotto scalare del versore normale con il gradiente

$$\partial_{\mathbf{v}} f(\mathbf{x}) = \mathbf{v} \cdot \nabla f(\mathbf{x})$$

Usando la disuguaglianza di Cauchy-Schwarz, possiamo dire che

$$-||\nabla f(\mathbf{x})|| \leq \partial_{\mathbf{v}} f(\mathbf{x}) \leq ||\nabla f(\mathbf{x})||$$

Detto in modo semplice, il gradiente ci dice la **direzione da intraprendere per salire o scendere, il più rapidamente possibile**: se ci muoviamo lungo la direzione del gradiente in salita, stiamo crescendo il più velocemente possibile  $\|\nabla f(\mathbf{x})\|$ , se guardiamo verso il basso, stiamo scendendo il più rapidamente possibile  $-\|\nabla f(\mathbf{x})\|$ .

L'uguaglianza ha senso, se esiste un  $\lambda \in \mathbb{R}$  tale che

$$\mathbf{v} = \lambda \nabla f(\mathbf{x})$$

Se il nostro gradiente vale  $\nabla f(\mathbf{x}) = 0$ , significa che la nostra funzione è **stazionaria** nel punto identificato da  $\mathbf{x}$  (vedere le depressioni in blu scuro dei grafici visti sopra), che prende nome di **punto stazionario**.

Possono esserci più punti stazionari per una sola funzione e sta a noi capire se questi sono minimo, massimo o un punto di sella, di qui vedremo alcuni esempi fra poco.

### ⚠ Metodo di Hessian

Esiste un metodo per la valutazione dei punti stazionari di una funzione, che prende il nome di matrice di Hessian, o semplicemente, Hessian.

$$(\mathbf{H}_f)_{i,j} = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

Il motivo per cui non la usiamo è perché questo metodo non è conclusivo: non è decisionale, perché

- esistono dei casi in cui questo metodo non ci dice nulla sul punto, se sia minimo, massimo o nessuno di questi;
- finché fatto in  $\mathbb{R}^2$  ci è sufficiente guardare il determinante della matrice, ma quando saliamo di una dimensione nello spazio in  $\mathbb{R}^3$ , non ci basta più.

## Massimi e minimi

Se abbiamo una funzione reale  $f$  di  $n \in \mathbb{N}_+$  variabili reali, definita almeno in un aperto  $D \subseteq \mathbb{R}^n$ , se il gradiente di  $f$  è definito su tutto  $D$  allora  $f$  può ammettere **minimi locali** e **massimi locali** nei punti in cui  $f$  è stazionaria in  $D$ .

### ≡ Calcolo degli stazionari di una funzione 1

Cerchiamo il minimo locale della funzione  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$  per un aperto


$$f(x, y) = -2x^2 - 3y^2 + 4xy + 10$$

1. calcoliamo il gradiente

$$\nabla f(x, y) = (4y - 4x, 4x - 6y)$$

2. troviamo il punto stazionario risolvendo il sistema lineare di 2 equazioni

$$f(x, y) = \begin{cases} 4y - 4x = 0 \\ 4x - 6y = 0 \end{cases} \begin{cases} y = x \\ x = 0 \end{cases} \rightarrow f(0, 0) = 10$$



Siccome la nostra funzione ha un gradiente, essa si annullerà in un solo punto e quindi il nostro punto è un punto globale

$$f(x, y) = -2(x - y)^2 - y^2 + 10$$

per qualsiasi copia  $(x, y)$ ,  $f(0, 0) = 10$  ovvero massimo globale

### ≡ Calcolo degli stazionari di una funzione 2

Consideriamo la funzione definita in  $f : D \rightarrow \mathbb{R}$

$$f(x, y) = 2x^2 + 5y^2 + 4$$

per una palla chiusa  $D = \mathcal{B}_2[1, 0]$  ( $r = 2$ , centro  $[1, 0]$ ).


Ricordiamo che, per un insieme compatto (chiuso e limitato), se la funzione è continua questa ammette almeno un minimo globale e un massimo globale.

1. calcoliamo il gradiente

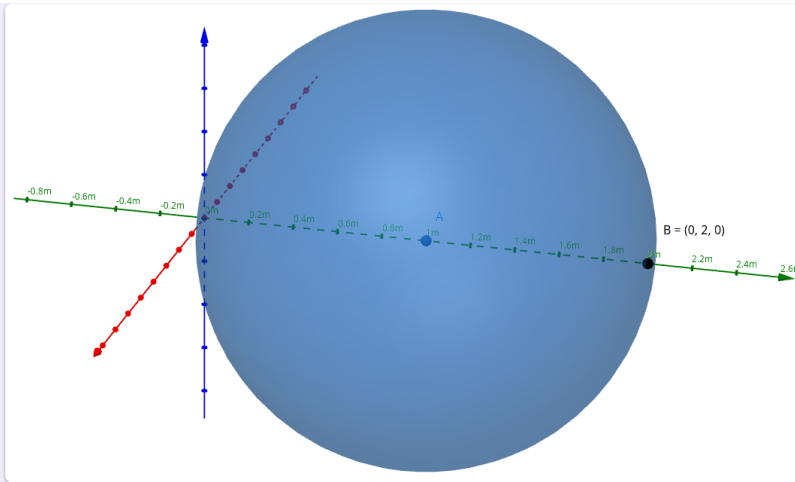
$$\nabla f(x, y) = (4x, 10y)$$

2. troviamo il punto stazionario risolvendo il sistema di 2 equazioni lineari

$$f(x, y) = \begin{cases} 4x = 0 \\ 10y = 0 \end{cases} \begin{cases} x = 0 \\ y = 0 \end{cases} \rightarrow f(0, 0) = 4$$



Attenzione al fatto che il punto appena trovato non è globale, perché ci basta prendere un altro punto nel dominio, come  $f(1, 0) = 6$  per cambiare appunto il risultato (vedere il punto nero  $B$  nell'immagine sotto).



Ragionando sempre sulla sfera, siccome sappiamo che a prescindere esistono punti globali, questi non possono fare altro che esistere sulla frontiera (o bordo) della sfera

$$\partial D = \{(x, y) : (x - 1)^2 + y^2 = 4\}$$

che in funzione di  $x$  viene espressa come

$$y^2 = 4 - (x - 1)^2$$

che per la funzione  $g(x)$  dipendente solo da  $x$ , sostituendo ci fa ottenere

$$g(x) = 2x^2 + 5 \cdot [4 - (x - 1)^2] + 4 = -3x^2 + 10x + 19$$

Il massimo globale si troverà nel punto di soluzione della nostra parabola con concavità verso il basso

$$P\left(\frac{5}{3}, \frac{4\sqrt{2}}{3}\right)$$

## Algoritmo di discesa del gradiente

L'algoritmo di discesa del gradiente, va alla ricerca di un minimo locale per una funzione definita in tutto  $\mathbb{R}^n$ , che ammette gradiente nello stesso spazio.

L'algoritmo funziona in modo "greedy", spostandosi sempre nella direzione puntata dal gradiente.

```
function gradient_descent(f, x, α)
    g ← ∇f(x)
    while g ≠ 0 do
        v ← -g / ||g||
        x ← x + αv
        g ← ∇f(x)
    end while
    return x
end function
```

- $f$  è la funzione per la quale vogliamo cercare un minimo locale;
- $\mathbf{x}$  è il punto di partenza;
- $\alpha$  la quantità che detta la velocità di discesa;
- $\mathbf{g}$  è il gradiente calcolato per la funzione  $f$ ;
- $\mathbf{v}$  la direzione.

Calcoliamo il gradiente di  $f$  chiamandolo  $\mathbf{g}$ .

- Se  $\mathbf{g} = 0$  siamo arrivati a un punto stazionario e l'algoritmo si ferma, dicendoci che quello trovato è un punto e non procediamo (l'algoritmo non sa nulla di dove siamo, sa solo che ha trovato qualcosa)
- Se  $\mathbf{g} \neq 0$  allora del gradiente, quello che a noi interessa, è la direzione contraria a quella di crescita, siccome stiamo cercando i minimi.
  - Prendiamo il gradiente  $\mathbf{g}$  e lo dividiamo per la sua norma  $\|\mathbf{g}\|$ , ottenendo un versore  $\mathbf{v}$  (vettore a norma 1) che cambieremo di segno per rispecchiare il ragionamento appena fatto
  - Prendiamo  $\mathbf{x}$  dalla quale siamo partiti e procediamo nella direzione  $\mathbf{v}$  per una quantità  $\alpha$
  - Ricalcoliamo il gradiente  $\mathbf{g}$

Quello che otteniamo, sarà alla fine almeno un minimo locale  $\mathbf{x}$ .

---

L'algoritmo non è infallibile:

- non è detto che termini, perché se prendiamo certe funzioni, tipo un paraboloide, questo comincerà a scendere senza però fermarsi mai;
- non è detto che restituisca minimo o massimo, come nel caso di una sella;
- ha quantità di problemi numerici non banale, siccome dividendo, accumuleremo errore di calcolo a causa della piccolezza del numero a cui cercheremo di avvicinarci.

L'algoritmo è tuttavia semplicissimo e lo useremo per addestrare le nostre reti neurali.

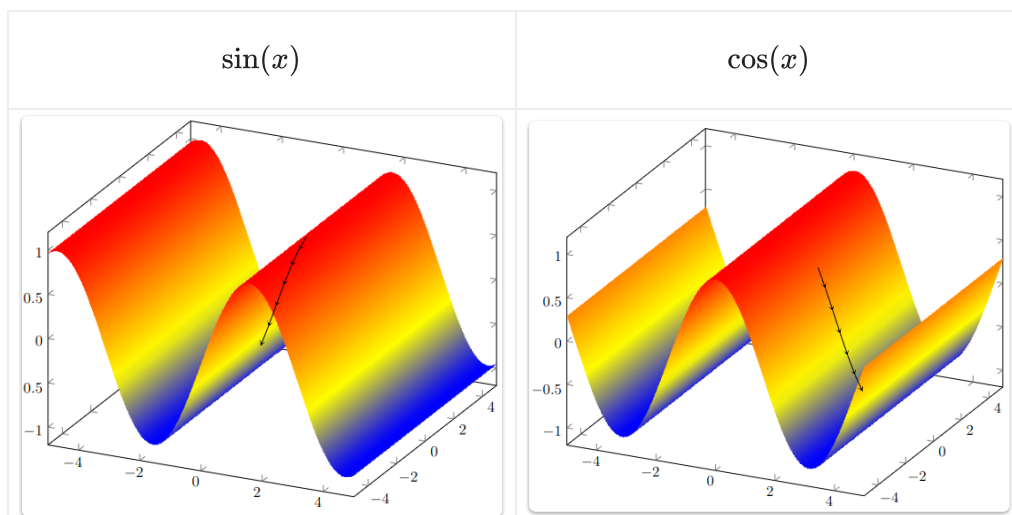
## Illustrazioni di alcuni punti stazionari

Nelle tabelle in basso, vediamo alcuni esempi curiosi di calcolo del punto stazionario.

L'immagine è stata ottenuta usando il pacchetto TikZ della suite LaTeX, usando un algoritmo per la generazione del grafico in un range definito.

Gli step sono stati normalizzati e aumentati a massimo 80.


(<https://tex.stackexchange.com/questions/544796/plot-gradient-descent>)






$$\tan(0.5x)$$

Notare come l'algoritmo riesca a trovare con successo un minimo locale




$$\tan(x)$$

L'algoritmo ha trovato effettivamente un minimo locale, ma non il minimo globale (notare come le frecce puntino verso sinistra)



$$\cos(0.8x) \cdot \cos(0.6y) \cdot e^{0.1x}$$

Esempio interessante di funzione



$$x^2 - y^2$$

La tipica "sella"

